

전체 연령·65세 이상 온열질환 예측 분석 보고서

1. 분석 목적

- 기상 조건으로 전체 연령과 65세 이상 전국 일일 환자 수를 각각 예측한다.
- 두 모델의 데이터·전처리는 아래에서 비교하고, 이후 분석·평가·그래프는 모델별로 구분한다.
- 전국 단위 환자 수 예측이며 개인 발병 확률이나 외출 안전 판정 모델은 아니다.

2. 모델별 사용 데이터

구분	전체 연령 모델	65세 이상 모델
분석 대상	전국 일일 전체 연령 환자 수	전국 일일 65세 이상 신고 건수
분석 기간	2022~2025년 감시기간	2022~2025년 감시기간
환자 원본	2022~2024년 연도별 XLS 2025년 통합 CSV	2011~2025년 신고 원본 CSV → 2022~2025년·65세 이상 추출
일별 자료	heat_illness_daily_2022_2025.csv	heat_illness_elderly65_daily_2022_2025.csv
학습 파일	train_dataset.csv	train_dataset_elderly65_2022_2025.csv
기상 자료	2022~2025년 ASOS 일자료 날짜별 전국 평균 8개 변수	기존과 같은 ASOS 전국 평균 기상 변수 8개 사용
최종 규모	536일 × 11열 연도별 134일	536일 × 11열 연도별 134일
환자 합계	2022: 1,564 / 2023: 2,818 2024: 3,704 / 2025: 4,460명	2022: 445 / 2023: 869 2024: 1,174 / 2025: 1,341건
예측 정답	total_patients	elderly_patients

3. 모델별 데이터 전처리

처리 단계	전체 연령 모델	65세 이상 모델
환자 가공	2022~2024년 XLS 일별 집계와 2025년 통합 자료 결합	원본에서 연도·나이 필터 적용 65세 이상 3,829기록 날짜별 집계
날짜·인코딩	환자 CSV UTF-8-SIG 기상 CSV CP949; 날짜 형식 통일	가공 CSV UTF-8-SIG 날짜를 기존 기상 자료와 맞춤
기상 처리	일강수량 결측치를 0으로 처리 8개 기상값을 날짜별 전국 평균	기존 학습 CSV의 기상값 8개 사용 전체 연령 환자 수는 가져오지 않음
날짜 결합	환자 자료·기상 자료의 공통 날짜로 병합 → 536일	일별 538일 → 기상값 있는 536일 5/17·5/19(2023년, 고령자 0건) 제외
0건·중복	일별 날짜 중복 여부 확인	신고 없는 날짜는 신고 0건 환자 ID가 없어 반복행 임의 삭제 안 함
최종 확인	결측치 0·중복 날짜 0 기존 일별 환자 자료와 집계 일치	결측치 0·중복 날짜 0 추출 원본과 집계 일치, 총 3,829건
입력·정답	X: 기상 변수 8개 y: 전체 연령 환자 수	X: 기상 변수 8개 y: 65세 이상 신고 건수
출처 차이	기존 집계는 공식 연보 합계와 일치	새 원본은 2022~2024년 연보와 불일치. 원인 미확인·강제 보정 안함

※ 일강수량의 결측치를 0으로 간주한 것은 현재 전처리 방식이며, 미관측과 무강수의 구분은 추가 검토가 필요하다.
입력 변수: 평균·최저·최고기온, 일강수량, 평균 풍속, 평균 상대습도, 합계 일조시간, 합계 일사량.


모델 1. 전체 연령 - EDA·학습·평가

4. 전체 연령 EDA - 현황과 분포

연도	분석 일수	환자 합계(명)	일평균(명)
2022	134	1,564	11.7
2023	134	2,818	21.0
2024	134	3,704	27.6
2025	134	4,460	33.3


- 분석 기간의 환자 합계는 2022년 1,564명에서 2025년 4,460명으로 증가했다. 이 자료만으로 증가 원인을 기온 변화 하나로 단정할 수는 없다.

그림 1. 연도별 일일 온열질환자 수 변화



- 각 연도를 감시기간의 첫날부터 나란히 비교했다. 가로축은 실제 달력 날짜가 아니라 감시기간 내 순서이며, 일부 날짜에 환자 수가 크게 집중된다.


그림 2. 일일 온열질환자 수 분포



- 일평균 23.4명, 중앙값 9명, 최댓값 259명이다. 낮은 환자 수에 날씨가 많이 물리고 오른쪽 꼬리가 긴 분포다. 세로축은 환자 합계가 아닌 날짜 수다.


5. 전체 연령 EDA - 기상 조건과의 관계

그림 3. 최고기온과 전국 일일 온열질환자 수



- 날짜별 전국 평균 최고기온이 높을수록 환자 수가 많은 경향이 나타난다. 같은 기온에서도 환자 수의 차이가 커 기온만으로 모든 변동을 설명하지는 못한다.

그림 4. 기상 변수와 환자 수의 상관계수



- 최고기온(0.722), 평균기온(0.672), 최저기온(0.548) 순으로 양의 상관관계가 크다. 일조시간·일사량도 양의 상관을 보이며, 상대습도의 선형 상관은 약하다.

※ 상관계수는 선형 관계이며 인과관계나 모델 중요도와 다르다. 전국 평균은 지역별 차이를 가릴 수 있다.

※ 아래 성능과 그래프는 전체 연령 모델에 해당한다. 차이가 가려질 수 있다.

6. 전체 연령 모델 학습·평가 및 중요도


- Decision Tree와 Random Forest를 비교한 뒤, 5겹 교차검증을 사용하는 GridSearchCV로 랜덤포레스트를 튜닝하였다. 아래 표는 학습 데이터와 테스트 데이터의 평가 결과를 구분한 것이다.

구분	평가 대상 데이터	MAE(명)	RMSE(명)	R ²
학습 평가	무작위 분리의 학습 데이터 428일	6.056	12.298	0.853
무작위 테스트	무작위 분리의 테스트 데이터 108일	9.700	14.871	0.846
연도 분리 테스트	2022~2024년 402일 학습 후, 2025년 134일 평가	13.128	23.960	0.686

- 학습 R²는 0.853이며, 무작위 테스트 R²는 0.846이다. 무작위 테스트의 MAE는 약 9.7명으로, 실제 환자 수와 예측값의 절대오차가 평균 약 9.7명이었다.
- 연도 분리 테스트에서는 R²가 0.686으로 낮아지고 MAE가 약 13.1명으로 커졌다. 새로운 연도에 대한 추가 검증이 필요하다. R²는 정확도가 아니라 결정계수이다.

* 최종 설정
: 나무 100개, 최대 깊이 7, 최소 분할 샘플 8, 최소 리프 샘플 5, max_features="sqrt", random_state=42.

그림 5. 최종 랜덤포레스트 기상 변수 중요도



- 최고기온 36.3%, 평균기온 27.4%, 최저기온 17.0%로 기온 변수의 중요도 합계는 약 80.7%다. 중요도는 모델 내부 지표이며 환자 발생의 인과적 기여율이 아니다.

7. 전체 연령 모델 - 데이터 파일과 연도별 평가

원본: heat_illness_2022.xls, heat_illness_2023.xls, heat_illness_2024.xls


2025년 원본 가공 자료: heat_illness_2025_unified.csv

일별 환자 수: heat_illness_daily_2022_2025.csv / 학습: train_dataset.csv

모델: model/saved/heat_patient_model.pkl / 기상 입력 변수 8개

기상 원본은 data/raw의 2022·2023·2024년 폴더와 2025년 ASOS CSV를 사용한다.

그림 6. 전체 연령 모델의 2025년 실제값·예측값



- 2022~2024년 학습 → 2025년 평가: R^2 0.686, MAE 13.128명, RMSE 23.960명.
- 기존 연도 평가 코드의 고정 설정으로 재현했다. 저장된 주 모델을 덮어쓰지 않았다.
- 설정이 전체 연도의 무작위 분리 과정에서 선택되었으므로 튜닝까지 독립된 연도 검증은 아니다.
- 무작위 평가와 연도 평가 결과를 함께 제시하고, 다른 연도에서 성능이 낮아지는 한계를 기록한다.

모델 2. 65세 이상 전국 일일 온열질환 신고 건수 예측

1. 고령자 현황 분석 결과

연도	분석 일수	신고 합계(건)	일평균(건)	최대(건)
2022	134	445	3.32	28
2023	134	869	6.49	58
2024	134	1,174	8.76	76
2025	134	1,341	10.01	89

- 총 3,829건이며 일평균은 7.14건이다. 데이터 출처와 전처리는 앞의 모델별 비교표에 정리하였다.
- 새 원본과 공식 연보의 집계 차이는 미해결이며, 공개 CSV 신고 건수를 기준으로 해석한다.
- * 자료 출처: <https://www.data.go.kr/data/15149889/fileData.do>

2. 고령자 모델 - 학습 및 평가 결과

- 학습 자료 안에서 GridSearchCV(cv=5)로 R²가 높은 설정을 선택하였다.

구분	평가 대상 데이터	MAE(건)	RMSE(건)	R²
학습 평가	무작위 분리 학습 428일	1.626	3.149	0.917
무작위 테스트	무작위 분리 테스트 108일	3.209	4.917	0.837
연도 분리 테스트	2022~2024년 402일 학습 2025년 134일 평가	4.174	7.687	0.687

- 주 모델은 학습 R² 0.917, 테스트 R² 0.837이며, 테스트에서 하루 평균 절대오차는 3.209건이다.
- 연도 평가에서는 R² 0.687, MAE 4.174건으로 새 연도 예측의 오차가 더 크게 나타났다.

* 교차검증 비교

실험	모델	교차검증 R²
무작위 학습 분할 내부	RandomForestRegressor	0.739
2022~2024년 내부	RandomForestRegressor	0.480
2022~2024년 내부	GradientBoostingRegressor	0.373

- 두 연도 실험 모델은 같은 자료·분할에서 비교했으며, 탐색한 후보에서는 랜덤포레스트가 더 높았다.
- 무작위 학습 분할과 연도 분리 실험은 조건이 다르므로 교차검증 점수를 직접 비교하지 않는다.


고령자 모델 설정 및 저장

항목	고령자 주 모델	연도 평가용 모델
학습 코드	model_train_elderly65.py	model_year_test_elderly65.py
학습 범위	2022~2025년 무작위 428일	2022~2024년 전체 402일
트리 개수	100	200
최대 깊이	10	20
최소 분할 샘플	5	3
최소 리프 샘플	2	1
max_features	sqrt	sqrt
random_state	42	42
저장 여부	모델·기상 컬럼 목록 저장	별도 연도 평가 실험용

- * 저장 파일: model/saved/heat_patient_elderly65_model.pkl
- 저장된 주 모델은 전체 536일 재학습 모델이 아니라 무작위 학습 분할 428일로 학습한 모델이다.
- 주 모델의 재로드 예측 및 연도 평가 고정 설정의 수치를 재확인하였다. 교차검증 점수는 실행 기록이다.
- 2025년 결과를 확인한 뒤 추가 실험을 진행했으므로 연도 평가는 완전히 독립된 최종 검증이 아니다.
- R²는 정확도가 아닌 결정계수이며, 평균 오차가 모든 날짜의 오차 범위를 뜻하지 않는다.


3. 고령자 EDA - 날짜별 변화와 분포

그림 1. 연도별 일일 고령자 신고 건수 변화



- 연도별 최대 일일 신고는 28·58·76·89건이었다. 여름철 일부 날짜에 신고가 집중되며, 연도 사이 빈 구간은 감시 기간 밖이므로 0건으로 해석하지 않는다.


그림 2. 일일 고령자 신고 건수 분포



- 일평균 7.14건, 중앙값 3건, 최댓값 89건이다. 낮은 신고 건수의 날짜가 많고 급증한 날짜는 드물어 오른쪽 꼬리가 길다. 드물다는 이유만으로 큰 값을 삭제하지 않는다.


4. 고령자 EDA - 기상 조건과의 관계

그림 3. 전국 평균 최고기온과 고령자 신고 건수



- 기온이 높은 구간에서 신고 건수가 많아지는 비선형 경향이 보인다. 비슷한 기온에서도 신고 건수가 달라 기온만으로 변동을 모두 설명할 수는 없다.


그림 4. 기상 변수와 고령자 신고 건수의 상관계수



- 최고기온 0.684, 평균기온 0.629, 최저기온 0.506 순으로 양의 상관이 크다. 상관관계가 인과관계를 뜻하지 않으며 습도의 약한 선형 상관을 건강 영향이 없다는 뜻으로 해석하지 않는다.

5. 고령자 EDA - 저장 모델의 변수 중요도

그림 5. 고령자 랜덤포레스트의 기상 변수 중요도




- 최고기온 36.0%, 평균기온 22.9%, 최저기온 17.3%로 세 기온 변수 합계는 약 76.2%다. 이는 나무 분할의 불순도 감소 기반 중요도이며 인과적 기여율이나 정확도가 아니다.
- 중요도 그래프는 무작위 분리로 학습·저장한 고령자 주 모델을 불러와 작성했다. 중요도 추출과 별도로 저장 모델의 predict 실행도 확인하였다.

6. 고령자 모델 - 결론 및 구현 현황

- 기존 전체 연령 모델을 보존하고, 65세 이상 신고 건수 예측용 랜덤포레스트를 별도로 학습·저장하였다. 고령자 주요 EDA 5종을 완료했다.
- 무작위 테스트에서는 R^2 0.837이었지만 새로운 연도에서는 성능 저하와 큰 오차가 관찰됐다. 두 결과와 데이터 출처의 불일치를 함께 보고한다.
- 전체 연령과 65세 이상 모델에 각각 데이터 분위수 기반 4단계 예측 등급을 적용하였다.
이 등급은 프로젝트 내부의 상대 기준이며 의학적으로 검증된 위험 기준이 아니다.
- Streamlit과 Next.js 화면에서 두 모델을 선택하고 전국 하루 평균 및 선택 지역·시간대의 참고 예측을 제공한다.
고령자는 전체 연령에 포함되므로 두 예측값을 합산하지 않으며, 두 모델은 별도로 해석한다.
- Open-Meteo 예보를 연결했고 기상청 API 키가 있으면 폭염특보를 함께 조회한다. 개인 발병 확률이나 외출 안전 판정으로 제공하지 않는다.

7. 고령자 모델 - 2025년 실제값·예측값

그림 6. 2022~2024년으로 학습한 고령자 모델의 2025년 예측



- 환자 증가·감소 흐름은 일부 따라가지만 급증 구간의 과소 예측과 일부 기간의 과대 예측이 보인다.
- 이 그림은 연도 평가용 모델의 결과이며, 성능과 설정은 앞의 학습·평가 표를 참고한다.

서비스 구현. Streamlit·Next.js

1. 공통 예측 흐름

- 사용자는 전체 연령 또는 65세 이상 모델과 날짜·지역·외출 시간·체류시간을 선택한다.
- Open-Meteo 예보를 전국 대표 지점의 하루 평균과 선택 지역의 외출 시간대 평균으로 각각 가공한다.
- 저장 모델의 weather_columns 순서에 맞춰 8개 기상 변수를 입력하고 예상 환자 수와 4단계 등급을 계산한다.
- 외출 안내는 모델 결과와 시간대 규칙을 결합한 참고 정보이며 의료 진단이나 안전 보증이 아니다.

2. Streamlit 앱

- Python 기반 분석형 화면으로 예측 결과, 모델 정보, 데이터 분석을 세 개 탭으로 제공한다.
- 사이드바에서 조건을 입력하며 전체 연령·65세 이상 모델의 성능과 학습 자료를 같은 화면에서 비교한다.

그림 1. Streamlit 예측 화면

Deploy

예측 정보 입력

예측 대상
전체 연령

예측 날짜
2026 / 09 / 06

외출 지역
서울

외출 시작 시간
9시

야외 체류시간(분)
60

예측하기

온열질환자 수 예측

기상 정보를 입력하면 예상 환자 수를 확인할 수 있습니다.

예측 결과 모델 정보 데이터 분석


예측 결과

사이드바에서 조건을 선택한 후 '예측하기' 버튼을 눌러주세요.

3. Next.js 웹사이트

- Next.js API Route가 Python 연결 스크립트를 실행해 기존 모델·데이터·weather_api.py를 재사용한다.
- 예측 조건과 결과를 한 화면에 구성하고 데스크톱과 모바일 환경에 대응하는 반응형 UI를 제공한다.

그림 2. Next.js 예측 웹사이트



4. 구현 구조와 검증

- 공통 Python 계층: 저장 모델 로드, 기상 예보 수집·단위 변환, 위험 등급, 외출 안내를 담당한다.
- Streamlit 계층: app.py가 Python 함수를 직접 호출한다.
- 웹 계층: Next.js API Route → web/scripts Python 연결 스크립트 → 공통 Python 계층 순서로 호출한다.
- Python 3.13 환경에서 모델·분석 데이터 로드를 확인했고 Next.js는 npm ci, ESLint, 프로덕션 빌드를 통과했다.
- 기상청 폭염특보는 .streamlit/secrets.toml의 KMA_API_KEY가 있을 때 조회하며, 키가 없어도 앱과 분석 화면은 실행된다.

5. 결론 및 한계

- 두 저장 모델과 두 사용자 화면을 연결해 예측·설명·EDA 결과를 확인할 수 있는 서비스 형태로 확장하였다.
- 모델은 전국 평균 기상과 전국 신고 환자 수의 관계를 학습하므로 선택 지역의 실제 환자 수를 직접 예측하지 않는다.
- 외출 시간대 결과는 선택 지역 기상값을 기존 전국 모델에 넣은 참고값이며 개인별 건강 상태를 반영하지 않는다.
- 연도 분리 평가에서 성능 저하가 확인되었으므로 새 연도 자료를 이용한 지속적인 재검증이 필요하다.